

Rapport de projet long

(Master TRIED)

ACP hybride et méthode des noyaux pour données mixtes
fonctionnelles et vectorielles

Pierre Chambet

Mars 2026

Résumé

Contexte. Ce mémoire conclut le **projet long** du **Master TRIED**. Il s'intéresse au **regroupement** de données (classification non supervisée) lorsque chaque individu combine une partie **fonctionnelle** (une courbe) et une partie **vectorielle** (un vecteur de covariables). La question est de savoir comment utiliser **ensemble** ces deux types d'information pour former des groupes cohérents, plutôt que de les traiter à part.

Table des matières

1	Chapitre 1 : Introduction et formulation du problème	3
1.1	Contexte océanographique et acoustique	3
1.2	Formulation statistique : individu mixte (X, Z)	3
1.3	Deux mondes, une distance à construire	3
1.4	Évolution du stage et périmètre empirique	3
2	Chapitre 2 : Architectures de distances et hybridation de surface	3
2.1	Lien avec la proposition de stage et chaîne de calcul	3
2.2	Briques de niveau 0 : D_0, D_1, D_s	4
2.3	Compromis fonctionnel $D_p(\alpha)$ (niveau 1)	4
2.4	Pondération fonctionnel / vectorielle : $D_w(\alpha, \omega)$ (niveau 2)	5
2.5	Noyaux produit et distance $D_K(\alpha)$	5
2.6	Stratégies A, B et C : même ingrédients, géométries différentes	5
2.7	Architecture à deux niveaux : vue d'ensemble	6
2.8	Hybridation tardive et absence de covariance croisée	7
3	Chapitre 3 : ACP hybride fonctionnelle-vectorielle (HFV)	7
3.1	Pourquoi une autre géométrie que les distances du chapitre 2 ?	7
3.2	Intuition : espace hybride $\mathbb{H}$	7
3.3	L'estimation matricielle en trois temps	7
3.4	Axes principaux et structure des vecteurs propres	8
3.5	Scores hybrides et reconstruction	9
3.6	De la reconstruction HFV à la matrice de distances noyau	9
4	Chapitre 4 : Dispositif empirique et verrou du non-supervisé	9
4.1	Les données d'étude (Le Matériel)	9
4.2	Le verrou du calibrage	11
4.3	Le paradoxe de la silhouette	11
4.4	Stabilisation par instabilité bootstrap (Fang & Wang)	12

5	Chapitre 5 : Données simulées	14
5.1	Instabilité bootstrap sur les scénarios simulés	14
5.2	Scénarios S1 à S4 : interprétation du signal	15
5.3	Comparaison des stratégies : tableau récapitulatif (ARI moyen)	16
5.4	Effondrement en S4 : transparence sur les limites	16
5.5	Paradoxe silhouette / ARI sur les données simulées	16
6	Chapitre 6 : Jeux réels étiquetés	17
6.1	Résultats comparatifs (trois jeux)	17
6.2	Interprétation	17
7	Conclusion générale	17

1 Chapitre 1 : Introduction et formulation du problème

1.1 Contexte océanographique et acoustique

En océanographie, une grandeur utile pour l’acoustique sous-marine est la *célérité* du son dans l’eau, obtenue à partir des champs physiques (par exemple température, salinité) via une équation d’état. On peut alors s’intéresser à des *profils verticaux* de célérité, tout en disposant en parallèle d’informations vectorielles (localisation, indices résumés, etc.). Les données à traiter sont donc à la fois **fonctionnelles** (la courbe) et **vectorielles** (le bloc de variables). L’enjeu du projet long est d’étudier comment **regrouper** de tels individus **mixtes** avec des méthodes adaptées, plutôt que de séparer artificiellement les deux types d’information.

1.2 Formulation statistique : individu mixte (X, Z)

On modélise chaque individu par un couple

$$(X, Z), \quad X \in \mathbb{H} = L^2(\mathcal{T}), \quad Z \in \mathbb{R}^p,$$

où X est une fonction observée sur un domaine $\mathcal{T} \subset \mathbb{R}$ (muni de la mesure usuelle pour définir l’espace de Hilbert $\mathbb{H}$), et Z est un vecteur de covariables dans $\mathbb{R}^p$. Un exemple possible dans le cadre océanographique est un profil de célérité pour X et des variables résumées pour Z ; le reste du mémoire reste volontairement *général* pour s’attacher au problème statistique (coupler fonctionnel et vecteur), indépendamment du détail d’une application.

1.3 Deux mondes, une distance à construire

Du point de vue mathématique, la difficulté centrale est que la structure d’ $\mathbb{H}$ (produit scalaire, distance L^2 , possibilité de dériver pour capturer la stratification) et la structure euclidienne de $\mathbb{R}^p$ ne sont pas directement comparables. On ne dispose pas d’un espace produit canonique où une norme unique agrégerait sans arbitrage l’écart fonctionnel et l’écart vectoriel : toute métrique sur le couple (X, Z) est une *construction*, paramétrée par des choix de poids, de normalisation, de filtrage par rapport à la dérivée, ou par passage par des représentations intermédiaires (scores, noyaux). La question « comment faire coexister le continu et le discret ? » est donc le cœur du projet long : il s’agit de définir des mesures de similarité qui respectent à la fois la régularité fonctionnelle et la géométrie vectorielle, sans fusion naïve qui laisserait l’une des modalités dominer l’autre par la seule taille des composantes ou l’échelle de discrétisation.

1.4 Évolution du stage et périmètre empirique

Le projet long imposait l’exploration des données mixtes via une application au **SHOM** (Service hydrographique et océanographique de la Marine). Cependant, l’évaluation d’algorithmes non supervisés impliquant une vérité terrain absente de ces données brutes, l’étude s’est orientée vers des **jeux publics étiquetés** (jeux réels) et des données de **simulation** contrôlées. Le partitionnement reste néanmoins aveugle aux étiquettes, l’ARI n’intervenant qu’en stricte évaluation *a posteriori*.

2 Chapitre 2 : Architectures de distances et hybridation de surface

2.1 Lien avec la proposition de stage et chaîne de calcul

Les constructions ci-dessous répondent au programme du projet long : combiner une composante fonctionnelle (profils lissés X_i) et un vecteur $Z_i \in \mathbb{R}^p$. En pratique, les courbes sont d’abord lissées

(splines, représentation fonctionnelle discrète sur grille fine), puis une analyse en composantes principales fonctionnelles (FPCA) fournit des scores pour la stratégie A et des évaluations $X_i(t)$, $X'_i(t)$ pour les intégrales définissant D_0 et D_1 . Cette réduction fonctionnelle est le passage obligé annoncé dans le sujet lorsque l'on suit la voie « discrétisation puis méthodes euclidiennes ».

2.2 Briques de niveau 0 : D_0 , D_1 , D_s

Nous partons de trois mesures complémentaires de dissimilarité : écart global de niveau (D_0), écart de dynamique de forme (D_1), écart dans l'espace des covariables (D_s). Aucune ne suffit seule à résumer le couple (X, Z) ; la suite du chapitre ne fait qu'assembler ces briques selon des règles de fusion différentes.

On note $\mathcal{T}$ le domaine de la profondeur (ou du temps) et $X_i, X_j \in L^2(\mathcal{T})$ les profils lissés.

Distance de niveau D_0 . La distance L^2 entre courbes mesure l'écart global des profils :

$$D_0(i, j) = \sqrt{\int_{\mathcal{T}} [X_i(t) - X_j(t)]^2 dt}. \quad (1)$$

Elle est sensible au décalage vertical entre trajectoires et moins à la seule différence de forme lorsque les niveaux restent proches.

Distance de forme D_1 . La dérivée première X'_i encode la dynamique de stratification (taux de variation du profil). On pose

$$D_1(i, j) = \sqrt{\int_{\mathcal{T}} [X'_i(t) - X'_j(t)]^2 dt}. \quad (2)$$

D_1 privilégie la proximité des formes au sens des gradients, au prix d'une sensibilité accrue au bruit d'estimation si le lissage est insuffisant.

Distance vectorielle D_s . Les covariables Z_i sont standardisées variable par variable (moyenne nulle, variance unitaire), notées Z_i^{std} . La distance euclidienne associée est

$$D_s(i, j) = \|Z_i^{\text{std}} - Z_j^{\text{std}}\|_2. \quad (3)$$

Elle ne dépend pas des courbes ; inversement, D_0 et D_1 ignorent Z . Les trois briques sont donc *complémentaires* mais prises isolément *non suffisantes* pour représenter la similarité du couple (X, Z) .

2.3 Compromis fonctionnel $D_p(\alpha)$ (niveau 1)

Les ordres de grandeur de D_0 et D_1 diffèrent en général : sans mise à l'échelle, un seul des deux termes pourrait dominer le mélange et fausser le sens du curseur α . On normalise donc par les maxima empiriques sur l'échantillon :

$$\tilde{D}_0 = \frac{D_0}{\max D_0}, \quad \tilde{D}_1 = \frac{D_1}{\max D_1}, \quad (4)$$

de sorte que $\tilde{D}_0$ et $\tilde{D}_1$ sont comparables (typiquement dans $[0, 1]$ hors diagonale). On combine ensuite les deux termes normalisés avec un paramètre $\alpha \in [0, 1]$ qui joue le rôle de *curseur* entre niveau et forme :

$$D_p(\alpha) = \sqrt{(1 - \alpha) \tilde{D}_0^2 + \alpha \tilde{D}_1^2}, \quad \alpha \in [0, 1]. \quad (5)$$

Pour $\alpha = 0$ (resp. $\alpha = 1$), on retrouve $\tilde{D}_0$ (resp. $\tilde{D}_1$) à une normalisation près. Le paramètre α règle exclusivement le compromis *intra-fonctionnel* entre amplitude et dynamique ; il ne mélange pas encore le fonctionnel avec le vectoriel.

2.4 Pondération fonctionnel / vectorielle : $D_w(\alpha, \omega)$ (niveau 2)

On normalise également la partie vectorielle par le maximum empirique, $\tilde{D}_s = D_s / \max D_s$, pour aligner l'échelle de D_s sur celle des distances fonctionnelles déjà calibrées. La distance mixte pondérée utilisée dans la stratégie B est

$$D_w(\alpha, \omega) = \sqrt{\omega D_p(\alpha)^2 + (1 - \omega) \tilde{D}_s^2}, \quad \omega \in [0, 1]. \quad (6)$$

Ici α intervient dans $D_p(\alpha)$ (choix niveau / forme dans le bloc fonctionnel), tandis que ω pondère explicitement la contribution de la partie fonctionnelle $D_p(\alpha)$ par rapport à la partie vectorielle $\tilde{D}_s$. Le symbole ω est réservé à cette distance D_w ; au chapitre 3, le coefficient r du produit scalaire hybride (10) joue un tout autre rôle (pondération dans un produit scalaire théorique, pas dans une matrice de distances PAM).

Sous les normalisations adoptées, $D_w(\alpha, \omega)$ est une métrique sur les deux composantes $D_p(\alpha)$ et $\tilde{D}_s$; elle peut donc alimenter un partitionnement de type PAM (k-médoïdes) sur la matrice de dissimilarités complète.

2.5 Noyaux produit et distance $D_K(\alpha)$

On ne combine pas les distances comme dans (6) : on suit la construction de Ferreira & de Carvalho (2014), imposée par le stage. On passe par des **similarités** (plus grandes lorsque les individus sont proches) dérivées de $D_p(\alpha)$ et de D_s , on les multiplie, puis on en déduit une matrice de distances pour le PAM.

On pose

$$K_f(i, j) = \exp\left(-\frac{D_p(\alpha)_{ij}^2}{2\sigma_f^2}\right), \quad (7)$$

$$K_s(i, j) = \exp\left(-\frac{D_s(i, j)^2}{2\sigma_s^2}\right), \quad (8)$$

avec σ_f et σ_s fixés par les médianes des distances non nulles sur l'échantillon (deux échelles, une par bloc). Le score global est le produit $K(i, j) = K_f(i, j) K_s(i, j)$. La matrice de distances associée est

$$D_K(i, j) = \sqrt{K(i, i) + K(j, j) - 2K(i, j)}. \quad (9)$$

Les noyaux gaussiens transforment chaque distance en similarité dans $[0, 1]$; la médiane fixe un ordre de grandeur typique sans ajouter une grille de réglage par jeu. Par rapport à la combinaison additive (6), le produit $K_f K_s$ exige que les deux modalités soient *simultanément* proches pour obtenir une grande similarité globale.

2.6 Stratégies A, B et C : même ingrédients, géométries différentes

Les trois stratégies répondent au même besoin (fusionner X et Z pour le clustering) avec des géométries différentes : A agrège des coordonnées dans un seul espace euclidien, B combine additivement des carrés de distances normalisées, C exige via le produit $K_f K_s$ que les deux modalités soient *simultanément* proches. En pratique, nous ne les considérons pas comme interchangeables : A est la ligne de référence “réduction puis k -means”; B offre un contrôle explicite de ω sur la dissimilarité PAM; C, imposée par le cadre Ferreira & de Carvalho (2014), est celle que les résultats agrégés du chapitre 5 tendent à favoriser lorsque le signal fonctionnel et vectoriel se combinent favorablement (sans écarter A lorsque le vecteur porte seul l'étiquette, voir S3 et Tecator).

Stratégie A (RS-PCA et k -means). La FPCA fournit L scores $\xi_{i1}, \dots, \xi_{iL}$ par individu ; le vecteur Z_i est standardisé comme pour D_s . On forme le vecteur $W_i = (\xi_{i1}, \dots, \xi_{iL}, Z_{i1}^{\text{std}}, \dots, Z_{ip}^{\text{std}})$ dans $\mathbb{R}^{L+p}$, puis on centre-réduit chaque colonne de la matrice ainsi construite. Le clustering est un k -means avec distance euclidienne, soit la norme $\|\cdot\|_2$ sur l'espace des W_i . Il n'y a pas d'ACP séparée sur Z dans cette chaîne de référence : seule la FPCA résume le fonctionnel, le bloc Z restant en coordonnées physiques renormalisées. Du point de vue conceptuel, c'est une fusion *par concaténation* de coordonnées réduites, suivie d'une norme euclidienne unique sur le vecteur agrégé.

Stratégie B (PAM sur D_w). Pour chaque couple (α, ω) d'une grille régulière (21×21 valeurs, pas 0,05 sur $[0, 1]$ pour chaque paramètre), on calcule la matrice $D_w(\alpha, \omega)$ et on applique PAM. La géométrie est entièrement définie par la dissimilarité (6), donc par une combinaison *additive* des carrés des contributions fonctionnelle et vectorielle après normalisations.

Stratégie C (PAM sur D_K). La **stratégie C** est le partitionnement PAM à partir de la matrice $D_K(\alpha)$ construite comme en (9) (noyaux produit de la sous-section précédente). On balaie la même grille en α que pour D_p (21 valeurs, pas 0,05) ; chaque valeur fixe $D_p(\alpha)$, donc le noyau K_f , avec σ_f et σ_s donnés par les médianes. La géométrie est donc multiplicative ($K_f K_s$), par opposition à la combinaison additive de la stratégie B en (6).

Aucune de ces trois procédures n'est intrinsèquement « supérieure » sur le plan théorique : elles traduisent des arbitrages géométriques distincts.

2.7 Architecture à deux niveaux : vue d'ensemble




FIGURE 1 – Architecture hiérarchique des distances : cette figure résume le flux $D_0, D_1, D_s \rightarrow D_p \rightarrow D_w$ ou D_K . **Bleu** = fonctionnel, **rouge** = vectoriel, **vert** = mixte. Les niveaux 0 et 1 sont purement fonctionnels ; le niveau 2 combine les deux sources.

Distance	Ce qu'elle voit	Ce qu'elle rate
D_0	Niveau vertical des courbes	Forme / dynamique
D_1	Forme / vitesse de changement	Niveau vertical
D_s	Position dans $\mathbb{R}^p$	Les courbes entièrement

TABLE 1 – Trois distances de base (D_0, D_1, D_s) : elles se complètent et aucune ne suffit seule pour résumer le couple (X, Z) .

Stratégie	Représentation	Méthode de clustering	de Fusion fonctionnel / vectoriel
A (FPCA+Z)	Vecteur W = k -means (distance euclidienne) [ξ_{FPCA} Z] standardisé		Concaténation dans $\mathbb{R}^{L+p}$
B (D_w)	Matrice de distances $D_w(\alpha, \omega)$	PAM (k-médoides)	Somme pondérée $D_p(\alpha)^2 + \tilde{D}_s^2$
C (D_K)	Matrice de distances $D_K(\alpha)$	PAM (k-médoides)	Produit de noyaux gaussiens $K_f \cdot K_s$

TABLE 2 – Résumé des trois stratégies : même ingrédients (D_0 , D_1 , D_s), géométries de fusion différentes.

2.8 Hybridation tardive et absence de covariance croisée

Les stratégies A, B et C réalisent une hybridation *tardive* : elles évaluent séparément les écarts fonctionnels et vectoriels avant de les fusionner. Par construction, aucune n'estime la covariance *croisée* inter-blocs (tel le bloc V_{yx} du chapitre suivant) avant de définir la métrique. Elles ignorent donc la structure potentielle de liaison statistique entre variations temporelles de X et covariables Z . Cette limite fondamentale au niveau de la modélisation de surface motive l'ACP hybride (HFV) du chapitre 3, qui diagonalise explicitement une matrice de covariance jointe en amont du clustering.

3 Chapitre 3 : ACP hybride fonctionnelle-vectorielle (HFV)

3.1 Pourquoi une autre géométrie que les distances du chapitre 2 ?

Les stratégies A, B et C construisent des dissimilarités à partir de résumés déjà calculés séparément (FPCA d'un côté, Z de l'autre), puis les combinent ou les injectent dans des noyaux. L'ACP hybride (HFV) répond à une question différente : *où* la variabilité commune entre les deux modalités est-elle modélisée avant toute distance de clustering ? L'idée est d'estimer une *covariance jointe* sur des coordonnées réduites, puis de diagonaliser cette matrice pour obtenir des axes qui mélangent explicitement les deux blocs. La présentation qui suit enchaîne les étapes dans l'ordre du calcul.

3.2 Intuition : espace hybride $\mathbb{H}$

En théorie, l'individu est une paire (X, Z) dans un espace de Hilbert $\mathbb{H}$ mélangeant une composante fonctionnelle (L^2) et une composante vectorielle ($\mathbb{R}^p$). On introduit un produit scalaire hybride qui additionne la partie continue et la partie discrète, avec un coefficient positif calibrant le poids relatif du vectoriel :

$$\langle h_1, h_2 \rangle_{\mathbb{H}} = \langle f_1, f_2 \rangle_{\mathbb{F}} + r \langle v_1, v_2 \rangle_{\mathbb{R}^p}, \quad (10)$$

de sorte qu'aucune modalité n'écrase l'autre par la seule échelle de mesure.

3.3 L'estimation matricielle en trois temps

Le modèle en dimension infinie se ramène à un vecteur de dimension finie $(L+J)$ par individu.

Étape 1 : réduction séparée. Une FPCA sur les courbes lissées fournit L scores par individu, $\eta_{i1}, \dots, \eta_{iL}$, sur les fonctions de base de la FPCA, $\phi_1, \dots, \phi_L$. Le vecteur Z est centré et réduit, puis résumé par une ACP classique en J scores $\gamma_{i1}, \dots, \gamma_{iJ}$.

Calibration du coefficient r . Les échelles de dispersion (variances) des résumés fonctionnels et vectoriels diffèrent considérablement. Afin d'éviter que l'une n'écrase algébriquement l'autre lors de la définition de la géométrie jointe, on introduit un simple ratio de pondération empirique r . Celui-ci correspond au strict rapport des variances des blocs respectifs *avant* fusion :

$$r = \frac{\text{tr Cov}(\eta)}{\text{tr Cov}(\gamma)}. \quad (11)$$

Ce ratio r permet d'équilibrer et de fixer mathématiquement le poids relatif des deux produits scalaires.

Étape 2 : vecteur d'état joint. On encode ce poids en posant $\tilde{\gamma}_{ij} = \sqrt{r} \gamma_{ij}$: la norme euclidienne sur le vecteur concaténé reproduit alors le facteur r du produit scalaire hybride (10). On concatène les deux blocs en un seul vecteur de $\mathbb{R}^{L+J}$:

$$x_i = (\eta_{i1}, \dots, \eta_{iL}, \tilde{\gamma}_{i1}, \dots, \tilde{\gamma}_{iJ}). \quad (12)$$

Étape 3 : covariance des coordonnées réduites. On centre les colonnes de la matrice des x_i , puis on estime la covariance empirique en notant les x_i comme vecteurs colonnes centrés :

$$V = \frac{1}{n-1} \sum_{i=1}^n x_i x_i^\top. \quad (13)$$

Elle admet la partition par blocs fonctionnel / vectoriel :

$$V = \begin{bmatrix} V_y & V_{yx} \\ V_{xy} & V_x \end{bmatrix}, \quad (14)$$

où V_y et V_x portent la variabilité propre à chaque modalité. Le bloc croisé vérifie $V_{yx} = V_{xy}^\top$ et mesure la *covariance croisée* entre scores fonctionnels et scores vectoriels : c'est le bloc qui manquait aux constructions « de surface » du chapitre 2. Tant que V_{yx} n'est pas nul, les fluctuations des deux sources ne sont pas traitées comme indépendantes au moment de définir la géométrie jointe.

3.4 Axes principaux et structure des vecteurs propres

Les directions de variance maximale sous contrainte de norme 1 sont les vecteurs propres de V (théorème spectral) : pour un axe m , la variance projetée s'écrit $\langle e_m, V e_m \rangle$. Chaque vecteur propre se décompose selon les deux blocs :

$$e_m = \begin{bmatrix} c_m \\ d_m \end{bmatrix}, \quad c_m \in \mathbb{R}^L, \quad d_m \in \mathbb{R}^J, \quad (15)$$

ce qui signifie qu'un axe dominant peut combiner à la fois un motif sur les scores FPCA et un motif sur les scores vectoriels ; ce n'est pas une suite « d'abord fonctionnel, puis vectoriel », mais une *intrication* dans un repère orthogonal commun.

3.5 Scores hybrides et reconstruction

Le score de l'individu i sur l'axe m est la coordonnée sur e_m , soit la projection de x_i sur cet axe :

$$\rho_{im} = \sum_{h=1}^L \eta_{ih} c_{mh} + \sum_{j=1}^J \tilde{\gamma}_{ij} d_{mj} = \sum_{h=1}^L \eta_{ih} c_{mh} + \sqrt{r} \sum_{j=1}^J \gamma_{ij} d_{mj}. \quad (16)$$

La partie fonctionnelle de l'axe se lit comme une fonction dans $L^2(\mathcal{T})$ en combinant les fonctions de base de la FPCA :

$$\psi_m(t) = \sum_{h=1}^L c_{mh} \phi_h(t). \quad (17)$$

La partie vectorielle se lit dans $\mathbb{R}^p$ en combinant les directions principales de l'ACP sur Z (vecteurs propres unitaires de la covariance empirique de Z standardisé), notées $w_1, \dots, w_J$:

$$\theta_m = \sum_{j=1}^J d_{mj} w_j. \quad (18)$$

Ainsi ρ_{im} est bien la somme des contributions fonctionnelle (via les η_{ih} et c_{mh}) et vectorielle (via les $\tilde{\gamma}_{ij}$ et d_{mj}), et la reconstruction « lisible » de l'axe m sépare explicitement ψ_m (continu) et θ_m (discret dans $\mathbb{R}^p$), sans passer par un retour mécanique aux p coordonnées brutes de Z si l'on reste dans le sous-espace des J premières composantes. Dans la mise en œuvre numérique du stage, ce sont surtout les courbes qui sont reconstruites explicitement dans L^2 à partir des loadings sur les ϕ_h ; la composante vectorielle se déduit des scores γ_{ij} et des d_{mj} , ou du profil θ_m , plutôt qu'un vecteur Z entier réaffiché dans $\mathbb{R}^p$ à chaque étape.

Les courbes reconstruites à partir des composantes hybrides restent dans le sous-espace engendré par les (ϕ_h) , mais les coefficients ne sont plus ceux de la seule FPCA initiale : ils sont *informés* par la structure de liaison entre η et γ contenue dans V , en particulier dans V_{yx} .

3.6 De la reconstruction HFV à la matrice de distances noyau

Une fois les trajectoires reconstruites dans le sous-espace engendré par les (ϕ_h) à partir des scores hybrides, on mesure une dissimilarité de type L^2 discrétisée entre les courbes reconstruites, notée $\mathcal{D}_{\text{recon}}$. Sur le bloc vectoriel Z (standardisé), on utilise la distance euclidienne usuelle $\mathcal{D}_Z$. À chaque bloc on associe un noyau gaussien (écarts-types σ_f et σ_s fixés à partir des médianes des distances intra-bloc), on forme le produit des noyaux comme au chapitre 2 pour (9), puis une matrice de distances $\mathcal{D}_K$ induite par ce noyau hybride. Le partitionnement est réalisé par une méthode adaptée aux matrices de dissimilarités (PAM), avec le même nombre de groupes k que pour les autres stratégies comparées.

4 Chapitre 4 : Dispositif empirique et verrou du non-supervisé

4.1 Les données d'étude (Le Matériel)

Pour **tester** le pipeline et **mesurer** les comportements des méthodes (ARI, matrices de confusion, etc.), on s'appuie sur des **données étiquetées** (réelles ou simulées) en réservant les labels à l'évaluation, pas au choix des hyperparamètres. La seule voie pour *fixer* simultanément le nombre de groupes K , la séparation entre classes sur la composante fonctionnelle et sur le vecteur Z , et les niveaux de bruit, est l'expérimentation sur données simulées dont la loi est connue par construction.

La simulation retenue s'appuie sur un générateur de courbes simulées avec bruit contrôlé : courbes discrétisées sur une grille de temps $(t_1, \dots, t_N)$ sur $[0, 1]$ ($N = 60$) dans une base trigonométrique, coefficients de classe modulés par $\delta = (\delta_1, \delta_2, \delta_3)$, où δ_1 et δ_2 règlent l'écart des

coefficients fonctionnels (niveau et dynamique de forme dans le générateur) et δ_3 la séparation des moyennes du bloc Z . Le bloc $Z \in \mathbb{R}^p$ ($p = 20$) est bruité par un gaussien additif de variance τ^2 ; le signal fonctionnel observé l'est également par un **bruit gaussien** additif de variance σ^2 . Les effectifs par classe sont égaux (100 individus par classe, $n = 300$) et le nombre de groupes simulé est $K = 3$. Quatre scénarios S1-S4 font varier les δ (tableau 3).

Les **trois jeux réels** publics (Canadian Weather, Berkeley Growth, Tecator) offrent des étiquettes de référence consensuelles pour une **évaluation a posteriori par ARI** sans participer au réglage des hyperparamètres. Le tableau 3 récapitule à la fois les scénarios simulés et les trois jeux réels.

Bloc 1 : données simulées				
Scénario	δ_1	δ_2	δ_3	Effectif / K
S1	1,0	1,0	1,0	$n = 300, K = 3$
S2	1,0	1,0	0,5	id.
S3	0,5	0,5	1,0	id.
S4	0,5	0,5	0,5	id.
Bloc 2 : jeux réels				
Jeu	Courbes $X(t)$	n	Covariables Z	k / classes
Canadian Weather	Temp. annuelle	35	lat., long., précip.	4 régions
Berkeley Growth	Courbe taille-âge	93	taille fin., croiss.	2 (sexe)
Tecator	Absorbance NIR selon longueur d'onde	215	eau, protéines	3 (gras)

TABLE 3 – Matériel expérimental : scénarios simulés (δ_1 niveau fonctionnel, δ_2 forme, δ_3 séparation sur Z) et jeux réels utilisés aux chapitres 5 et 6. Pour Tecator, la partie fonctionnelle est l'absorbance mesurée en fonction de la longueur d'onde (un spectre par individu).

Pour chaque scénario simulé, le benchmark répète 50 fois la chaîne complète (lissage, FPCA, distances, stratégies A/B/C et chaîne HFV) avec des graines indépendantes. Les hyperparamètres dépendant de la silhouette sont cherchés sur la même grille discrète que le pipeline principal (pas 0,05 sur $[0, 1]$) ; l'ARI sert *uniquement* à l'évaluation.




FIGURE 2 – Canadian Weather : séparation visuelle des profils entre les quatre régions retenues comme vérité de groupe pour l'ARI (35 courbes de température annuelle lissées) ; elle illustre le jeu du tableau 3.

4.2 Le verrou du calibrage

Les hyperparamètres k , α et ω conditionnent l'intégralité de la partition induite. En l'absence de labels opérationnels, l'optimisation des stratégies A, B et C s'appuie obligatoirement sur des critères internes (ex : silhouette ou instabilité bootstrap). La chaîne HFV, quant à elle, calibre son ratio interne r en amont sans nécessiter de recherche sur (α, ω) . Dans tout le pipeline de ce dispositif, l'ARI reste strictement confiné à un rôle d'évaluation extérieure et ne participe jamais à la calibration.

4.3 Le paradoxe de la silhouette

Étant donnée une matrice de distances D et une partition $\mathcal{C} = \{C_1, \dots, C_k\}$, la silhouette de l'individu i affecté au cluster C_ℓ compare la cohésion intra-groupe à la séparation inter-groupes :

$$s(i) = \frac{b(i) - a(i)}{\max\{a(i), b(i)\}}, \quad (19)$$

où $a(i)$ est la distance moyenne de i aux autres points de C_ℓ et $b(i)$ la distance moyenne minimale aux points d'un autre cluster. La silhouette moyenne $\bar{s} = \frac{1}{n} \sum_i s(i)$ synthétise la qualité géométrique de la partition *dans la métrique choisie*. Le protocole classique du projet maximise $\bar{s}$ sur une grille de (α, ω) à k fixé, ce qui est cohérent avec une recherche de groupes compacts et bien séparés *au sens de D* .

Jeu	K	Choix par silhouette (D_w , PAM)			Maximum d'ARI sur la grille (éval.)			ΔARI
		(α, ω)	$\bar{s}$	ARI	(α, ω)	$\bar{s}$	ARI	
Canadian Weather	4	(0,00,0,00)	0,448	0,616	(0,55,0,80)	0,311	0,898	0,283
Growth	2	(0,00,0,00)	0,554	0,424	(0,85,0,30)	0,372	0,756	0,332
Tecator	3	(0,00,1,00)	0,509	0,151	(1,00,1,00)	0,248	0,626	0,475

TABLE 4 – Paradoxe silhouette / ARI sur la stratégie B (D_w , grille 21×21 , pas 0,05, $k = K$ fixé à la vérité terrain pour l'évaluation). Le bloc central droit (maximum d'ARI sur la grille) est un *contrefactuel* : il suppose que l'on pourrait optimiser (α, ω) pour l'ARI, ce qui exige des étiquettes et ne correspond pas au réglage non supervisé. La dernière colonne donne $\Delta \text{ARI} = \text{ARI}_{\max} - \text{ARI}_{\text{sil}}$ (toujours ≥ 0).

Le point critique est que la silhouette $\bar{s}$ juge exclusivement la *séparation géométrique* conférée par la métrique employée. Une distance favorisant des amas compacts et sphériques obtiendra souvent une excellente silhouette, même si elle fragmente artificiellement les véritables sous-classes allongées. Ainsi, le couple (α, ω) maximisant $\bar{s}$ tend régulièrement à écraser l'une des dimensions (privilégiant par exemple le seul bloc discret) au détriment de l'information de forme requise pour maximiser l'ARI.

À k fixé, le tableau 4 illustre ce phénomène sur la stratégie B : le choix opérationnel par silhouette s'écarte systématiquement de l'optimum *contrefactuel* par ARI. L'écart ΔARI quantifie empiriquement ce coût. Ce constat impose de calibrer en priorité le paramètre macroscopique le plus structurant : le nombre de groupes k .

4.4 Stabilisation par instabilité bootstrap (Fang & Wang)

Puisque la silhouette s'avère fragile pour calibrer conjointement les poids géométriques, l'approche retenue est celle, complémentaire et non-supervisée, de **Fang & Wang** : minimiser l'*instabilité* des partitions évaluée par ré-échantillonnage bootstrap. Un k induisant des affectations très variables d'un tirage à l'autre est rejeté au profit du k le plus robuste, sans recours aux étiquettes. Ce critère reste toutefois une heuristique dont le comportement se dégrade lorsque le signal de groupe s'effondre (S3-S4, chapitre 5).

Procédure de Fang & Wang. Fang et Wang proposent de sélectionner k en *minimisant* une instabilité de clustering estimée par bootstrap. L'idée s'oppose aux procédures qui *maximisent* une similarité avec une partition de référence inconnue : deux échantillons bootstrap indépendants de taille n sont tirés avec remise ; on clusterise chacun avec le même algorithme et le même k sur la matrice de distances restreinte aux individus tirés, puis on compare les deux partitions après avoir prolongé les affectations à l'ensemble observé (classification des points non tirés au médioïde ou au centre le plus proche dans l'espace des distances). La désagrégation moyenne sur B répétitions donne une estimation $\text{Inst}(k)$ de l'instabilité attendue pour ce k . Le nombre de clusters retenu est

$$k_{\text{opt}} \in \arg \min_{k \in \mathcal{K}} \text{Inst}(k), \quad (20)$$

où $\mathcal{K}$ est un ensemble fini de candidats. Dans ce mémoire, on fixe $\mathcal{K} = \{2, \dots, 6\}$.

Mécanique du bootstrap. Formellement, pour un algorithme de clustering $\mathcal{A}$ et une distance D fixées, l'instabilité (au sens de Wang, estimée par bootstrap dans Fang & Wang) est liée à la variabilité des partitions induites par deux échantillons indépendants de même loi empirique. Si l'on note $\mathcal{P}_b^{(1)}$ et $\mathcal{P}_b^{(2)}$ les partitions obtenues à la répétition b après extension commune sur

$\{1, \dots, n\}$, et $\delta(\cdot, \cdot)$ une mesure de désaccord entre partitions (basée sur les co-affectations de paires), l'estimateur utilisé est de la forme

$$\text{Inst}(k) = \frac{1}{B} \sum_{b=1}^B \delta(\mathcal{P}_b^{(1)}, \mathcal{P}_b^{(2)}) . \quad (21)$$

Un k trop petit peut fusionner des modes réels et paraître stable ; un k trop grand fragmente le bruit et peut aussi instabiliser les frontières.

Couplage avec la grille (α, ω) et rôle de l'évaluation. *Côté calcul*, la matrice $D_w(\alpha, \omega)$ dépend du couple (α, ω) : pour chaque point de grille, on calcule D , puis $\text{Inst}(k)$ sur les candidats $k \in \mathcal{K}$ et l'on obtient $k_{\text{opt}}(\alpha, \omega)$. L'ordre opérationnel est donc une boucle sur (α, ω) avec comparaison des k à l'intérieur, et non un k unique fixé une fois pour toutes avant toute grille. On obtient ainsi une carte $(\alpha, \omega) \mapsto k_{\text{opt}}$ et des représentations d'instabilité (heatmaps) utiles au diagnostic. Les étiquettes, lorsqu'elles existent, ne participent pas à ce choix : elles servent uniquement à calculer l'ARI ou des matrices de confusion *après* fixation de (k, α, ω) .

Illustration sur les jeux réels. Comme annoncé en section 4.3, l'illustration sur la grille (α, ω) repose sur l'instabilité bootstrap, et non sur une carte de silhouette. Les calculs numériques utilisent $B = 150$ répétitions bootstrap, la grille (α, ω) de 21×21 points sur $[0, 1]$ (pas 0,05) et des candidats $k \in \{2, \dots, 6\}$, avec PAM sur $D_w(\alpha, \omega)$ comme dans le reste du pipeline. La figure 3 juxtapose les trois jeux réels du tableau 3 : chaque planche regroupe cinq cartes (α, ω) , une par valeur de k testée, plus une légende. L'échelle de couleur encode l'instabilité estimée (bleu : faible, rouge : forte) ; le symbole $\times$ indique le couple (α, ω) qui minimise l'instabilité *pour le k correspondant*. La juxtaposition met en évidence que la forme des zones “favorables” varie fortement d'un jeu à l'autre (nombre de classes de référence, géométrie du signal fonctionnel et du bloc Z), alors que le protocole reste identique.



(a) Canadian Weather ($K = 4$ régions).(b) Growth ($K = 2$, sexe).(c) Tecator ($K = 3$ classes de teneur en matières grasses).

FIGURE 3 – Instabilité bootstrap (Fang & Wang) sur D_w pour les trois jeux réels : cette figure montre comment les zones de faible instabilité (bleu) et forte instabilité (rouge) se réorganisent selon le jeu et selon k ; le symbole $\times$ marque le couple (α, ω) qui minimise l'instabilité pour le k de la planche. Comparaison directe des cartes par k et par (α, ω) .

Le même protocole d'instabilité bootstrap (grille (α, ω) , PAM sur D_w , candidats $k \in \{2, \dots, 6\}$, $B = 150$) est appliqué aux quatre scénarios S1-S4 issus des données simulées décrits section 4.1. Les heatmaps par scénario et l'interprétation quantitative (alignement de k_{opt} avec le vrai $K = 3$) sont présentées en section 5.1 du chapitre 5 (figure 4).



En synthèse : (i) la silhouette reste un critère interne lisible mais sujette au paradoxe de la séparation géométrique ; (ii) le choix de k à (α, ω) fixé peut s'appuyer sur la minimisation de l'instabilité au sens de Fang & Wang ; (iii) l'ARI et les partitions de référence restent des outils d'évaluation, pas d'optimisation opérationnelle en contexte non étiqueté. Les chapitres 5 et 6 rapportent les performances sur ce matériel.

5 Chapitre 5 : Données simulées

5.1 Instabilité bootstrap sur les scénarios simulés

Les mêmes principes qu'en section 4.4 (grille en (α, ω) , PAM sur D_w , recherche de k par instabilité bootstrap) ont été appliqués aux données simulées, en quatre scénarios S1-S4. Un bilan agrégé (une graine par scénario) indique : pour S1, environ 91 % des couples (α, ω) sélectionnent le k_{opt} égal au vrai $k = 3$; pour S2, environ 72 % ; pour S3, la proportion tombe à environ 8 % et la médiane de k_{opt} se décale vers des valeurs trop grandes ; pour S4, aucun couple ne retient $k = 3$ (médiane et mode vers 6). La figure 4 montre, pour chaque scénario, les cartes d'instabilité

par k sur la grille (α, ω) (une graine de référence par scénario) : les zones de faible instabilité cessent d'être alignées avec le vrai k lorsque le rapport signal / bruit global devient défavorable. L'augmentation spectaculaire de l'instabilité bootstrap face au très fort bruit (scénario S4) valide ici la pertinence du critère de Fang & Wang : il agit comme un véritable diagnostic signalant la désintégration de la structure robuste de clustering. Ce garde-fou évite d'imposer de fausses séparations artificiellement dans le bruit, un sur-apprentissage évident qu'une maximisation aveugle par la silhouette de surface aurait malheureusement pu masquer.

(a) S1 : signal fort sur $(\delta_1, \delta_2, \delta_3)$.(b) S2 : affaiblissement de δ_3 .(c) S3 : affaiblissement fonctionnel (δ_1, δ_2) .

(d) S4 : affaiblissement global.

FIGURE 4 – Données simulées (même protocole $B = 150$, grille 21×21 , $k \in \{2, \dots, 6\}$) : cette figure montre que l'alignement entre faible instabilité et le vrai $K = 3$ se dégrade quand les δ du générateur `Cas2_deriv` (section 4.1) passent du régime favorable (S1-S2) au régime difficile (S3-S4). Lecture identique à la figure 3.

5.2 Scénarios S1 à S4 : interprétation du signal

Les triplets δ sont ceux du tableau 3.

S1 : (1, 1, 1). Signal fort sur les trois leviers ; le classement ARI met en tête la stratégie C (D_K surface), puis la chaîne HFV+ D_K , puis les approches qui partagent les mêmes scores sur D_1 et la stratégie B (tableau 5).

S2 : (1, 1, 0.5). Même intensité fonctionnelle que S1, mais δ_3 réduit la séparation entre moyennes de Z ; la stratégie C reste en tête, suivie des blocs D_1 / B / D_f à ARI identique, puis D_0 et la chaîne HFV. La stratégie A se dégrade (signal vectoriel moins marqué).

S3 : (0.5, 0.5, 1). Fonctionnel affaibli, vectoriel fort : le classement se renverse. La stratégie A domine, suivie de D_s puis de la stratégie C ; les méthodes fortement ancrées sur la forme fonctionnelle chutent.

S4 : (0.5, 0.5, 0.5). Affaiblissement global : le meilleur ARI moyen est atteint par la baseline D_1 , suivie de la stratégie C et de la stratégie A ; toutes les valeurs restent basses, ce qui traduit le caractère frontière du scénario.

5.3 Comparaison des stratégies : tableau récapitulatif (ARI moyen)

Le tableau 5 synthétise l'ARI moyen de chaque méthode sur les quatre scénarios. Les hyperparamètres relevant de la silhouette sont fixés comme dans le pipeline ; l'ARI n'intervient qu'en *évaluation a posteriori*.

Méthode	S1		S2		S3		S4		Moy. glob.	
	ARI	$\bar{s}$	ARI	$\bar{s}$	ARI	$\bar{s}$	ARI	$\bar{s}$	ARI	$\bar{s}$
Baseline D_0	0,830	0,290	0,830	0,290	0,226	0,222	0,226	0,222	0,528	0,256
Baseline D_s	0,567	0,144	0,333	0,105	0,511	0,127	0,247	0,088	0,414	0,116
Stratégie A (FPCA+Z)	0,782	0,163	0,524	0,125	0,623	0,139	0,315	0,111	0,561	0,134
Stratégie B (D_w , sil.)	0,873	0,351	0,873	0,351	0,239	0,225	0,238	0,225	0,556	0,288
Stratégie C (D_K surface)	0,938	0,176	0,887	0,147	0,464	0,095	0,317	0,085	0,651	0,126
Baseline D_1	0,873	0,351	0,873	0,351	0,378	0,164	0,378	0,164	0,626	0,257
$D_f(\alpha)$ (sil.)	0,873	0,351	0,873	0,351	0,237	0,225	0,237	0,225	0,555	0,288
HFV + D_K (reconstr.)	0,897	0,160	0,802	0,130	0,433	0,097	0,301	0,088	0,608	0,118

TABLE 5 – Comparaison des performances sur données simulées. La silhouette ($\bar{s}$) permet de sélectionner les hyperparamètres (sans étiquettes), et l'ARI mesure la capacité finale de l'algorithme à retrouver les vraies classes.

Lecture globale. Les moyennes globales confirment l'ordre de grandeur attendu : stratégie C ($\approx 0,65$), puis D_1 et la chaîne HFV+ D_K ($\approx 0,61$ - $0,63$), puis la stratégie A ($\approx 0,56$). Les baselines D_0 et D_s sont plus sensibles au scénario (voir S2-S3). En résumé, sur la moyenne des quatre scénarios, nous retenons la stratégie C comme approche de surface la plus régulièrement compétitive lorsque fonctionnel et vectoriel portent ensemble le signal (S1-S2) ; nous rappelons toutefois que S3 renverse l'ordre au profit de A et D_s lorsque seul le vecteur reste informatif.

5.4 Effondrement en S4 : transparence sur les limites

Pour S4 ($\delta = (0,5, 0,5, 0,5)$), les ARI du tableau 5 chutent simultanément : la meilleure moyenne est celle de D_1 ($\approx 0,38$), suivie de la stratégie C ($\approx 0,32$) et de la stratégie A ($\approx 0,32$). La chaîne HFV+ D_K se situe juste derrière ($\approx 0,30$). Ce constat s'interprète clairement : aucune des architectures développées dans ce mémoire ne *restaure* une structure absente au niveau du générateur. Une piste naturelle, non menée ici faute de temps, serait une pondération adaptative des modalités ou des distances en fonction d'un diagnostic de rapport signal / bruit, plutôt qu'un ω ou un α choisis sur toute la grille avec les mêmes poids du début à la fin de l'étude.

5.5 Paradoxe silhouette / ARI sur les données simulées

Le tableau 5 juxtapose, pour chaque scénario et en moyenne globale, l'ARI (évaluation) et la silhouette moyenne $\bar{s}$ sur les mêmes runs. On y lit le même type d'écart qu'en données réelles : le choix par silhouette sur la stratégie B (forte $\bar{s}$ sur D_1 / D_f en S1-S2) ne coïncide pas avec

le meilleur ARI; les approches noyau D_K / HFV+ D_K affichent des $\bar{s}$ plus modestes tout en restant compétitives au sens de l'ARI. Maximiser la cohérence géométrique interne ne coïncide donc pas avec la récupération des classes lorsque celles-ci existent pour l'évaluation.

En synthèse sur les données simulées : la stratégie C et les constructions autour de $D_p(\alpha)$ restent les plus utiles lorsque le signal est partagé entre fonctionnel et vectoriel; dès que l'une des deux sources faiblit fortement (S3 ou S4), il faut accepter soit un autre classement de méthodes, soit des ARI bas : ce n'est pas un défaut d'implémentation mais une limite du réglage fixe adopté.

6 Chapitre 6 : Jeux réels étiquetés

6.1 Résultats comparatifs (trois jeux)

Jeu	n / k	D_0		D_s		A		B (D_w)		C (D_K)		HFV+ D_K	
		Sil.	ARI	Sil.	ARI	Sil.	ARI	Sil.	ARI	Sil.	ARI	Sil.	ARI
Canadian Weather	35 / 4	0,285	0,229	0,448	0,616	0,395	0,748	0,448	0,616	0,329	0,686	0,332	0,686
Growth	93 / 2	0,402	0,115	0,554	0,424	0,360	0,682	0,554	0,424	0,261	0,368	0,273	0,368
Tecator	215 / 3	0,509	0,151	0,476	0,546	0,403	0,439	0,509	0,151	0,265	0,371	0,284	0,374

TABLE 6 – Résultats sur trois jeux publics. Stratégies B et C : (α, ω) ou α choisis par silhouette. Colonne HFV+ D_K : reconstruction par ACP hybride (covariance croisée) puis distance à noyau sur courbes reconstruites et Z (chapitre 3).

6.2 Interprétation

Stratégie A (FPCA+ Z , k-means) et ligne de base. Sur Canadian Weather et Growth, la stratégie A atteint le meilleur ARI du tableau 6. Sur Tecator, c'est la baseline D_s (seul bloc vectoriel) qui maximise l'ARI (0,546) : le signal discriminant y est surtout porté par les covariables chimiques, ce qui relativise l'apport de la forme spectrale pour cette étiquette de classe. La chaîne HFV+ D_K se situe au même ordre de grandeur que la stratégie C sur les trois jeux et rejoint l'ARI de C sur Canadian Weather (0,686), ce qui illustre le rôle de la covariance croisée lorsque les deux modalités sont jointement informatives.

Paradoxe silhouette / ARI sur données réelles. Pour la stratégie B, le couple (α, ω) maximisant la silhouette diverge systématiquement du couple qui maximiserait l'ARI : la silhouette sélectionne des configurations proches des baselines pures ($\omega \in \{0, 1\}$) plutôt que des mélanges hybrides équilibrés. Ce constat reproduit le paradoxe documenté en section 4.3 et s'observe de façon cohérente sur les trois jeux.

Poids de la forme (D_1) sous optimisation ARI. Sur les trois jeux, le paramètre α maximisant l'ARI (évaluation *a posteriori* par ARI uniquement) satisfait $\alpha \geq 0,6$: la dynamique de forme est systématiquement plus discriminante que le seul niveau vertical. Cette observation confirme le rôle informatif de D_1 pour les stratégies qui utilisent explicitement $\mathcal{D}_p(\alpha)$ et plaide pour ne pas fixer $\alpha = 0$ par défaut en mode opérationnel.

7 Conclusion générale

Le problème abordé dans ce mémoire a été d'explorer le couplage entre données fonctionnelles et vectorielles pour le clustering non supervisé. L'étude empirique a démontré que l'ACP hybride (HFV) construite conjointement avec les distances noyaux constitue une alternative robuste et très interprétable face aux stratégies classiques d'hybridation (méthodes A, B, C). Toutefois,

aucune stratégie ne domine universellement : la performance reste logiquement subordonnée à la localisation du signal discriminant (forme de la courbe ou covariables de l'espace vectoriel).

Au-delà de ces comparaisons, la véritable complexité soulevée reste d'ordre structurel. L'expérience a mis en évidence le paradoxe entre la silhouette (mesure géométrique interne) et l'ARI (vérité terrain) : la recherche aveugle du meilleur compromis mathématique sans labels tend à écraser l'une des dimensions et à créer des clusters artificiels. C'est ici que se trouve le cœur scientifique et les perspectives de ce sujet : comment concevoir des algorithmes non-supervisés ou des heuristiques capables d'explorer intelligemment un ratio de variances inter-modalités *sans* la myopie des critères internes traditionnels ?

Références

- [1] Ferreira, L., & de Carvalho, F. A. (2014). *A novel approach to clustering mixed data*.
- [2] Fang, Y., & Wang, J. (2012). *Selection of the number of clusters via the bootstrap method*.