

Rapport d'instabilité (Fang & Wang)

Pierre Chambet

Mars 2026 (révisé en octobre 2026)

Résumé

On veut choisir k (nombre de clusters) et les paramètres de distance (α, ω) sans labels. Ce rapport se concentre sur une méthode de la littérature : **nselectboot** (Fang & Wang, 2012) qui minimise une **instabilité** mesurée par bootstrap. On teste une grille 21×21 en (α, ω) sur trois jeux de données; les labels ne servent qu'à évaluer l'ARI une fois k choisi. Une étude sur données simulées complète le rapport : données artificielles où le vrai k est connu.

Table des matières

1	Objectif de l'expérience 1	2
2	Les trois paramètres et les données	2
3	nselectboot (Fang & Wang, 2012)	2
3.1	Idée	2
3.2	PAM	2
3.3	Protocole (résumé)	2
3.4	Résumé sur la grille	2
4	Résultats : triplets retenus pour l'évaluation (nselectboot)	3
5	Matrices de confusion (nselectboot)	3
6	Heatmaps d'instabilité (nselectboot)	3
6.1	Canadian	4
6.2	Growth	4
6.3	Tecator	5
7	Etudes sur données simulées	5
8	Paramètres des expériences	7
9	Conclusion	8

1 Objectif de l'expérience 1

On veut choisir trois quantités **sans utiliser les labels pour le choix** :

- k : nombre de clusters.
- α : pondération entre distance sur les courbes (niveau) et sur les dérivées (forme).
- ω : pondération entre partie fonctionnelle et partie vectorielle (Z).

On estime un k_{opt} qui minimise l'instabilité bootstrap. On obtient une carte $(\alpha, \omega) \mapsto k_{\text{opt}}$ et des heatmaps d'instabilité par k . Les heatmaps montrent l'instabilité par (α, ω) et k : **bleu** = faible instabilité (bon), **rouge** = forte (mauvais).

2 Les trois paramètres et les données

- k : nombre de clusters testé dans $\{2, \dots, 6\}$.
- α : mélange D_0 (courbes) / D_1 (dérivées).
- ω : mélange distance fonctionnelle / distance sur Z .

Trois jeux de données (labels uniquement pour **évaluer** après coup) : Canadian Weather, Growth, Tecator. Les k_{vrai} utilisés dans les tableaux viennent des scripts `src/00_preprocess*.R` : Canadian (`CanadianWeather$region`), Growth (garçons/filles), Tecator via des règles définies dans le projet (seuils sur la matière grasse) — ce ne sont pas des vérités « absolues », mais des références pour comparer les partitions.

3 nselectboot (Fang & Wang, 2012)

3.1 Idée

On **minimise l'instabilité** : à chaque répétition bootstrap, on mesure à quel point deux partitions (obtenues sur deux échantillons bootstrap) se contredisent. Le k qui minimise cette instabilité moyenne est retenu pour le couple (α, ω) fixé.

3.2 PAM

PAM (k-medoids) travaille sur une matrice de distances ; les centres sont des **médoïdes** (individus réels), ce qui limite l'influence des outliers par rapport à des moyennes (k-means).

3.3 Protocole (résumé)

Pour chaque (α, ω) de la grille (21×21 , pas 0.05), avec $B = 150$:

1. Construire $D_w(\alpha, \omega)$ (même pipeline que le reste du projet : lissage, FPCA, distances).
2. Pour chaque $k \in \{2, \dots, 6\}$, `fpc::nselectboot` tire deux échantillons bootstrap d'indices, clusterise avec PAM sur les sous-matrices, complète les partitions sur tous les individus (classification croisée), puis agrège une mesure d'instabilité (voir code du package).
3. $k_{\text{opt}} = \arg \min_k \widehat{\text{instabilité}}(k)$.

Les fichiers `nselectboot_*.csv` et les figures `nselectboot_heatmap_*.png` synthétisent les résultats.

3.4 Résumé sur la grille

La médiane des k_{opt} sur les 441 couples vaut 2 pour les trois jeux (Canadian, Growth, Tecator). Le vrai k n'est retenu qu'en 1 couple sur 441 pour Canadian ($k_{\text{vrai}} = 4$), 276 sur 441 pour Growth ($k_{\text{vrai}} = 2$) et 4 sur 441 pour Tecator ($k_{\text{vrai}} = 3$). La réponse la plus fréquente est $k = 2$ (223 couples sur 441 pour Canadian, 382 pour Tecator), suivie de la plus grande valeur

testée, $k = 6$ (201 couples pour Canadian). Sur ces trois jeux, l'instabilité bootstrap ne retrouve donc pas le nombre de classes ; sur Growth, où $k_{\text{vrai}} = 2$, elle tombe juste parce que $k = 2$ est sa réponse par défaut.

4 Résultats : triplets retenus pour l'évaluation (nselectboot)

Pour les matrices de confusion, on prend le premier couple (α, ω) de la grille tel que $k_{\text{opt}} = k_{\text{vrai}}$ (sinon le plus proche), comme dans `generate_confusion_nselectboot.R`. Ce choix utilise le vrai k : les ARI ci-dessous illustrent la partition obtenue *lorsque* la méthode tombe sur le bon k , pas une procédure non supervisée.

Dataset	k_{vrai}	k	(α, ω)	ARI
Canadian	4	4	(0.25, 0.15)	0.62
Growth	2	2	(0.10, 0.05)	0.42
Tecator	3	3	(0.75, 0.10)	0.58

TABLE 1 – Partition évaluée avec les labels (ARI).

5 Matrices de confusion (nselectboot)

Lignes = vraies classes. Colonnes = clusters prédits.

Canadian ($k = 4$, ARI 0.62)

	C1	C2	C3	C4
Arctic	0	0	3	0
Atlantic	15	0	0	0
Continental	1	6	5	0
Pacific	0	4	0	1

Growth ($k = 2$, ARI 0.42)

	C1	C2
Fille	6	48
Garçon	29	10


Tecator ($k = 3$, ARI 0.58)

	C1	C2	C3
Maigre	19	0	93
Moyen	39	23	0
Gras	2	39	0


6 Heatmaps d'instabilité (nselectboot)

Pour chaque k , l'instabilité en fonction de (α, ω) . Bleu = bas = bon. $\times$ = meilleur (α, ω) pour ce k (voir script d'analyse).


6.1 Canadian



6.2 Growth



6.3 Tecator



7 Etudes sur données simulées

On applique la **même idée** que plus haut à des **données simulées**, en quatre situations notées S1 à S4. Dans chaque cas on connaît le vrai nombre de groupes $k_{\text{vrai}} = 3$ ici : on compare avec ce que la méthode retient sur la grille de (α, ω) .


Résultats chiffrés (seed fixée à 1). Pour chaque situation, le tableau indique : la part des couples (α, ω) de la grille pour lesquels le k choisi par la méthode est exactement le vrai k ; la *médiane* des k choisis sur toute la grille ; le *mode* (valeur la plus fréquente). Ces nombres viennent d’un calcul **plus léger** qu’en données réelles : grille 6×6 en (α, ω) (pas de 0,2 entre les points), et $B = 60$ tirages bootstrap au lieu de $B = 150$, pour limiter le temps de calcul.


Scénario	Seed	k_{vrai}	Prop. $k_{\text{opt}} = k_{\text{vrai}}$	Médiane k_{opt}	Mode k_{opt}
S1	1	3	0,917	3	3
S2	1	3	0,722	3	3
S3	1	3	0,083	5,5	6
S4	1	3	0,000	6	6

TABLE 2 – Données simulées : grille 6×6 , $B = 60$, graine 1. Un calcul aussi fin que sur les données réelles (21×21 , $B = 150$) est possible mais beaucoup plus long.

Observation sur les heatmaps. Pour chaque situation on trace une carte par valeur de k testée : le **bleu** correspond à une faible instabilité (c’est mieux), le **rouge** à une instabilité forte. En lisant les quatre figures avec le tableau 2, on voit une différence nette entre les deux premiers cas et les deux derniers. Pour **S1** et **S2**, les zones les plus bleues concernent souvent $k = 3$, ce qui va dans le sens du vrai k et du tableau (beaucoup de couples (α, ω) choisissent le bon k). Pour **S3** et surtout **S4**, les cartes montrent plutôt des instabilités minimales pour des k plus grands que 3 : visuellement, le “bon” niveau se décale, ce qui colle au fait que la méthode retient rarement ou jamais $k = 3$ sur toute la grille.

Les quatre cartes. Même réglage que pour le tableau 2.





8 Paramètres des expériences

- Grille $\alpha, \omega \in \{0, 0.05, \dots, 1\}$ (21×21).
- $k \in \{2, \dots, 6\}$, $B = 150$ répétitions bootstrap pour nselectboot.
- Même prétraitement que le pipeline principal :
src/01_lissage.R, src/02_fpca.R, src/03_distances.R.
- **Données simulées (réglage utilisé dans ce rapport)** : grille 6×6 en (α, ω) , $B = 60$, $k \in \{2, \dots, 6\}$. On peut en faire une version aussi fine que pour les données réelles (21×21 , $B = 150$), au prix d'un temps de calcul beaucoup plus long.

9 Conclusion

L'expérience 1 s'appuie sur une méthode publiée (instabilité bootstrap, Fang & Wang) pour choisir k à (α, ω) fixé, puis explore toute la grille. Le choix de k n'utilise pas les labels ; ceux-ci servent à l'ARI, et le vrai k sert à choisir le couple (α, ω) des matrices de confusion. Sur les trois jeux réels, la méthode répond $k = 2$ sur la majorité de la grille et ne retrouve pas le vrai nombre de classes (1 et 4 couples sur 441 pour Canadian et Tecator). En simulation, elle retrouve $k = 3$ quand les courbes portent un signal fort (S1, S2) et échoue sinon (S3, S4). Ces études simulées ne remplacent pas l'étude sur les trois jeux réels.

Références :

- Fang, Y., Wang, J. (2012). Selection of the number of clusters via the bootstrap method. *Computational Statistics and Data Analysis*, 56(3), 468–477.